

Лабораторная работа №1

Однослойный перцептрон: реализация, обучение и анализ

Цель работы

- Реализовать алгоритм обучения однослойного перцептрона с нуля (без готовых библиотек глубокого обучения).
- Изучить влияние параметров (скорость обучения, количество эпох, размер батча) на процесс обучения.
- Научиться подготавливать данные для нейронных сетей (нормализация, стратификация).
- Провести анализ полученных результатов и сделать выводы.

Обязательная часть

1. Подготовка данных

1. Загрузите или сгенерируйте набор данных для бинарной классификации с двумя числовыми признаками. (Рекомендуется использовать `make_classification` из `sklearn.datasets` с параметрами: `n_samples = 500`, `n_features = 2`, `n_redundant = 0`, `n_informative = 2`, `random_state = 42`, `n_clusters_per_class = 1`.)
2. Выполните стандартизацию признаков (Z-score) по обучающей выборке. Примените полученные параметры к тестовой выборке.
3. Разделите данные на обучающую (70%) и тестовую (30%) выборки с использованием стратификации для сохранения пропорции классов.

2. Реализация перцептрона

Реализуйте класс (или набор функций) для однослойного перцептрона. Реализация должна включать:

- Инициализацию весов $\mathbf{w}$ (небольшими случайными значениями) и смещения b (нулём).
- Функцию `sigmoid(z)`.
- Функцию `forward(X)`: возвращает $\hat{y}$ для входной матрицы X .
- Функцию `compute_loss(y_true, y_pred)`: среднее значение бинарной кросс-энтропии.
- Функцию `fit(X_train, y_train, X_val, y_val, epochs, lr, batch_size)`: обучение с использованием мини-батчей. В процессе обучения сохраняйте значения функции потерь на обучающей и валидационной выборках.

- Функцию `predict(X)`: возвращает 0 или 1 (порог 0.5 для $\hat{y}$).

Важно: не использовать готовые библиотеки машинного обучения (PyTorch, TensorFlow, Keras, `sklearn.linear_model`). Разрешены NumPy и стандартные математические функции Python.

3. Обучение и визуализация

1. Обучите перцептрон на подготовленных данных с гиперпараметрами: $\eta = 0.1$, количество эпох = 100, размер батча = 32.
2. Постройте графики изменения функции потерь на обучающей и валидационной выборках в зависимости от эпохи.
3. Вычислите точность (ассигасу) на обучающей и тестовой выборках после обучения.
4. Визуализируйте разделяющую границу (прямую $\mathbf{w}^T \mathbf{x} + b = 0$) на фоне точек данных.

4. Эксперименты и анализ

Проведите следующие эксперименты (каждый — отдельное обучение с фиксацией всех остальных параметров):

- **Влияние скорости обучения:** опробуйте $\eta = 0.001, 0.01, 0.5, 1.0$. Опишите, как меняется сходимость.
- **Влияние размера батча:** опробуйте `batch_size = 1, 16, 64, 256`. Сравните скорость сходимости и итоговую точность.
- **Влияние инициализации весов:** сравните нулевую инициализацию, маленькие случайные веса (по умолчанию), инициализацию с большими значениями (например, $\mathcal{N}(0, 10)$). Объясните, почему некоторые варианты плохо работают.

Для каждого эксперимента приведите графики loss и таблицу итоговых точностей.

Задания на дополнительные баллы

Задание 1. Собственный генератор данных

Реализуйте функцию генерации синтетических данных для бинарной классификации в двумерном пространстве. Функция должна позволять:

- Генерировать линейно разделимые данные: два гауссовых облака с заданными центрами и ковариационной матрицей.
- Генерировать нелинейно разделимые данные (например, «хот» — точки в углах квадрата, или «окружность» — точки внутри/снаружи круга).
- Добавлять контролируемый уровень шума (сдвиг метки с вероятностью p).

Обучите перцептрон на этих данных и покажите, когда классификация успешна (линейно разделимые данные), а когда — нет (XOR, окружность). Сделайте выводы о границах применимости перцептрона.

Задание 2. Дополнительные функции потерь и регуляризация

- Реализуйте функцию потерь Hinge loss (для $y \in \{-1, +1\}$) и обучите перцептрон с ней. Сравните с кросс-энтропией по скорости сходимости и точности.
- Реализуйте L2-регуляризацию для кросс-энтропии (коэффициент регуляризации λ). Исследуйте влияние λ на значение весов и качество обобщения. Покажите графики.

Задание 3. Метрики качества и анализ ошибок

Добавьте вычисление следующих метрик на тестовой выборке: precision, recall, F1-score, ROC-AUC. Постройте ROC-кривую. Проанализируйте, какие примеры классифицируются ошибочно (например, визуализируйте неправильные точки на графике).

Задание 4. Исследование сходимости градиентного спуска

Реализуйте градиентный спуск с моментом (momentum) и сравните его с обычным SGD на тех же данных. Исследуйте, при каких значениях импульса ($\beta = 0.5, 0.9, 0.99$) обучение ускоряется. Постройте графики loss для разных β .

Задание 5. Кросс-валидация и подбор гиперпараметров

Реализуйте 5-кратную кросс-валидацию для подбора скорости обучения η и размера батча. Приведите результаты (средняя точность и стандартное отклонение). Выберите лучшие гиперпараметры и обучите финальную модель на всех обучающих данных.